دانشگاه تهران، دانشکده مهندسی برق و کامپیوتر

آمار و احتمال مهندسی

تمرین کامپیوتری اول - قانون بیز

طراح: محمد قنبری

سوپروایزر: بابک حسینی محتشم

تاریخ تحویل: ۲۱ آبان ۱۴۰۵



۱. طبقه‌بندی با استفاده از قضیهٔ بیز

فرض کنید می‌خواهیم یک قارچ را بر اساس ویژگی‌های آن در یکی از دو کلاس زیر قرار دهیم:

- e: خوراکی (edible)
- p: سمی (poisonous)

در یک مسئلهٔ طبقه‌بندی، تعدادی نمونهٔ برچسب‌دار در اختیار داریم. هر نمونه شامل ویژگی‌ها و کلاس واقعی آن است. هدف ما این است که با استفاده از نمونه‌های آموزشی، کلاس یک نمونهٔ جدید را پیش‌بینی کنیم.

قضیهٔ بیز به ما کمک می‌کند احتمال تعلق یک نمونه به یک کلاس را با توجه به ویژگی‌های مشاهده‌شده محاسبه کنیم:

$$P(C \mid X) = \frac{P(X \mid C)P(C)}{P(X)}$$

در این رابطه:

- C کلاس مورد نظر است.
- X ویژگی‌های نمونهٔ جدید است.
- $P(C)$ احتمال اولیهٔ کلاس یا Prior است.
- $P(X \mid C)$ احتمال مشاهدهٔ ویژگی‌ها با فرض تعلق نمونه به کلاس C است.
- $P(C \mid X)$ احتمال تعلق نمونه به کلاس C پس از مشاهدهٔ ویژگی‌ها یا Posterior است.

برای طبقه‌بندی، معمولاً کافی است مقدار زیر را برای هر کلاس محاسبه کنیم:

$$P(C \mid X) \propto P(X \mid C)P(C)$$

زیرا $P(X)$ برای تمام کلاس‌ها یکسان است. بنابراین، کلاس پیش‌بینی‌شده برابر است با:

$$\hat{C} = \arg\max_{C} P(X \mid C)P(C)$$

چالش اصلی: فرض کنید نمونهٔ ما دارای ویژگی‌های زیادی باشد. برای مثال، در دیتاست کامل قارچ، ۲۲ ویژگی داریم. محاسبهٔ مستقیم احتمال مشترک تمام ویژگی‌ها با توجه به کلاس، به تعداد زیادی ترکیب و نمونهٔ آموزشی نیاز دارد.

برای ساده‌سازی، از یک فرض استفاده می‌کنیم: با دانستن کلاس نمونه، ویژگی‌ها را مستقل از یکدیگر فرض می‌کنیم. این فرض دقیقاً همان فرض ساده‌ساز مدل Naive Bayes است.

اگر ویژگی‌ها را با $X_1, X_2, \ldots, X_n$ نشان دهیم، خواهیم داشت:

$$P(X_1, \ldots, X_n \mid C) \approx \prod_{i=1}^{n} P(X_i \mid C)$$

در نتیجه، فرمول طبقه‌بندی به شکل زیر درمی‌آید:

$$\hat{C} = \arg\max_{C} P(C) \prod_{i=1}^{n} P(X_i \mid C)$$

این فرض در بسیاری از مسائل کاملاً دقیق نیست؛ با این حال، مدل حاصل ساده است و در مسائل مختلف می‌تواند عملکرد خوبی داشته باشد.

توجه: در این تمرین، تمام ویژگی‌ها دسته‌ای (categorical) هستند. بنابراین، احتمال‌های شرطی را با شمارش نمونه‌های آموزشی محاسبه خواهیم کرد.

۲. ساخت دستی یک مدل Naive Bayes

در این سوال، بدون استفاده از کد ، یک مدل سادهٔ Naive Bayes را به صورت دستی آموزش می‌دهیم.

فایل mushrooms_small_train.csv شامل سه ستون است:

- bruises: کبودی قارچ

- gill-size: اندازهٔ تیغه‌های زیر کلاه قارچ
- poisonous: کلاس قارچ؛ مقدار e به معنی خوراکی و p به معنی سمی است.

در این سوال، فقط از ۲۰ سطر اول فایل آموزشی استفاده کنید. داده‌ها به شکل زیر هستند:

poisonous	gill-size	bruises	سطر
p	b	f	۱
e	b	t	۲
e	b	f	۳
p	n	f	۴
p	n	f	۵
e	b	t	۶
e	b	t	۷
p	b	t	۸
e	b	t	۹
e	b	t	۱۰
e	n	f	۱۱
p	n	f	۱۲
e	b	f	۱۳
p	b	t	۱۴
e	b	f	۱۵
e	n	t	۱۶
e	b	t	۱۷
e	b	t	۱۸
p	b	f	۱۹
p	n	f	۲۰
p	b	f	۲۱

در این جدول، ۲۰ سطر اول داده‌های آموزشی هستند. سطر ۲۱ را به‌عنوان نمونهٔ جدید در نظر بگیرید و از برچسب واقعی آن استفاده نکنید.

الف) تعداد نمونه‌های هر کلاس را در ۲۰ سطر اول بشمارید و احتمال اولیهٔ هر کلاس را محاسبه کنید:

ب) احتمال‌های شرطی زیر را با استفاده از داده‌های آموزشی محاسبه کنید:

$$P(\text{bruises} = f \mid C)$$

$$P(\text{gill-size} = b \mid C)$$

این احتمال‌ها را برای هر دو کلاس e و p به دست آورید.

ج) با استفاده از فرض استقلال شرطی، امتیاز هر کلاس برای نمونهٔ سطر ۲۱ را محاسبه کنید:

$$S(C) = P(C)\, P(\text{bruises} = f \mid C)\, P(\text{gill-size} = b \mid C)$$

سپس کلاسی را انتخاب کنید که امتیاز بیشتری دارد.

۳. پیاده‌سازی Naive Bayes و ارزیابی مدل

اکنون باید محاسبات دستی را به کد پایتون تبدیل کنیم. از نوت‌بوک ارائه‌شده برای این تمرین استفاده کنید.

در این مرحله، مدل باید تمام احتمال‌ها را از روی داده‌های آموزشی محاسبه کند و برای هر نمونهٔ جدید، امتیاز تمام کلاس‌ها را به دست آورد و کلاس با بیشترین امتیاز را انتخاب کند .

بخش الف: بارگذاری داده‌ها

سلول بارگذاری داده‌ها را در نوت‌بوک کامل کنید. فایل‌های زیر در اختیار شما قرار گرفته‌اند . اول با فایل های small کار کنید تا debug کدتان آسان تر باشد ، سپس سراغ فایل های full بروید . (فایل های soybean برای بخش های بعدی هستند)

- mushroom_small_train.csv
- mushroom_small_test.csv
- mushroom_full_train.csv
- mushroom_full_test.csv
- soybean_train.csv
- soybean_test.csv

در نسخهٔ کوچک، ویژگی‌های ورودی bruises و gill-size هستند. در نسخهٔ کامل، تمام ۲۲ ویژگی دسته‌ای قارچ استفاده می‌شوند. ستون هدف در هر دو مجموعه poisonous است.

بخش ب: پیاده‌سازی

پیاده سازی را در نوت‌بوک کامل کنید تا بتوانید :

۱. احتمال اولیهٔ هر کلاس را از روی داده‌های آموزشی محاسبه کنید.

۲. احتمال مشاهدهٔ هر مقدار از هر ویژگی را به شرط کلاس محاسبه کنید.

۳. امتیاز هر کلاس را برای یک نمونهٔ جدید محاسبه کنید.

۴. با انتخاب کلاس دارای بیشترین امتیاز، برچسب نمونه را پیش‌بینی کنید.

بخش ج: ارزیابی

مدل خود را جداگانه روی مجموعهٔ کوچک و مجموعهٔ کامل آموزش دهید و دقت آن را روی مجموعهٔ آزمون مربوط به همان داده‌ها محاسبه کنید.

دقت (Accuracy) از رابطهٔ زیر به دست می‌آید:

$$\text{Accuracy} = \frac{\text{تعداد پیش‌بینی‌های درست}}{\text{تعداد کل نمونه‌های آزمون}}$$

نتایج را گزارش کنید .

بخش د: تحلیل

۱. آیا دقت مدل در دو مجموعه یکسان است؟ نتیجه را توضیح دهید.

۲. استفاده از ویژگی‌های بیشتر چه اثری بر تعداد احتمال‌های شرطی مورد نیاز دارد؟

۳. آیا نمی‌توان نتیجه گرفت که اضافه‌کردن ویژگی‌ها همیشه دقت مدل را افزایش می‌دهد؟

۴. مشکل Underflow و محاسبه در فضای لگاریتمی

در مدل Naive Bayes، برای هر کلاس امتیاز زیر را محاسبه می‌کنیم:

$$S(C) = P(C) \prod_{i=۱}^{n} P(X_i \mid C)$$

با افزایش تعداد ویژگی‌ها، تعداد احتمال‌هایی که در یکدیگر ضرب می‌شوند بیشتر می‌شود. از آنجا که هر احتمال بین صفر و یک است، حاصل‌ضرب آن‌ها ممکن است بسیار کوچک شود.

در محاسبات ممیز شناور کامپیوتر، اگر عددی بیش از حد کوچک شود، ممکن است به‌صورت صفر نمایش داده شود. این پدیده را Underflow می‌نامیم.

برای کاهش این مشکل، از لگاریتم استفاده می‌کنیم. با استفاده از خاصیت لگاریتم حاصل‌ضرب، خواهیم داشت:

$$\log S(C) = \log P(C) + \sum_{i=۱}^{n} \log P(X_i \mid C)$$

از آنجا که تابع لگاریتم صعودی است، انتخاب کلاس دارای بیشترین امتیاز با انتخاب کلاس دارای بیشترین لگاریتم امتیاز یکسان است:

$$\hat{C} = \arg\max_{C} \log S(C)$$

در نتیجه، به‌جای ضرب تعداد زیادی احتمال کوچک، لگاریتم آن‌ها را جمع می‌کنیم.

در نوت‌بوک، تابع محاسبهٔ امتیاز را به نسخهٔ لگاریتمی تبدیل کنید. سپس پیش‌بینی‌ها را با نسخهٔ مستقیم مقایسه کنید.

نسخهٔ لگاریتمی را روی مجموعهٔ کوچک و کامل اجرا کنید و به پرسش‌های زیر پاسخ دهید:

۱. آیا دقت نسخهٔ معمولی و نسخهٔ لگاریتمی یکسان است؟

۲. آیا در این دو مجموعه، شواهدی از Underflow واقعی مشاهده می‌کنید؟ نتیجه را با خروجی برنامه توضیح دهید.



۵. وقتی مدل هیچ امتیاز مثبتی ندارد

اکنون همان مدل Naive Bayes را روی مجموعهٔ دادهٔ Soybean Large اجرا می‌کنیم. این مجموعه شامل ویژگی‌های دسته‌ای متعددی است و برخلاف Mushroom، تعداد کلاس‌های آن بیشتر است.

معرفی مجموعه‌دادهٔ Soybean Large

مجموعه‌دادهٔ Soybean Large یک مجموعه‌داده در حوزهٔ یادگیری ماشین است که برای طبقه‌بندی بیماری‌ها و آسیب‌های گیاه سویا استفاده می‌شود. هر نمونه، وضعیت یک گیاه را با استفاده از مجموعه‌ای از ویژگی‌های توصیفی مشخص می‌کند. این ویژگی‌ها اطلاعاتی دربارهٔ شرایط رشد گیاه، وضعیت برگ‌ها، ساقه، ریشه، غلاف و دانه‌ها و همچنین برخی شرایط محیطی و کشاورزی ارائه می‌دهند.

در این تمرین، هر نمونه دارای ۳۵ ویژگی دسته‌ای است و هدف، پیش‌بینی کلاس آن در ستون class است. برخلاف مجموعه‌دادهٔ قارچ که تنها دو کلاس دارد، مجموعه‌دادهٔ Soybean Large شامل ۱۹ کلاس مختلف است. این کلاس‌ها انواع بیماری‌ها، آسیب‌های ناشی از علف‌کش‌ها و سایر اختلالات مشاهده‌شده در گیاه سویا را مشخص می‌کنند. برای مثال، برخی از کلاس‌ها عبارت‌اند از:

- diaporthe-stem-canker: شانکر ساقهٔ ناشی از دی‌آپورته
- charcoal-rot: پوسیدگی زغالی
- anthracnose: آنتراکنوز
- brown-spot: لکهٔ قهوه‌ای
- frog-eye-leaf-spot: لکه‌برگی چشم‌قورباغه‌ای
- herbicide-injury: آسیب ناشی از علف‌کش
- 2-4-d-injury: آسیب ناشی از نوعی علف‌کش

مقادیر عددی موجود در برخی ویژگی‌ها، کدهای مربوط به دسته‌های مختلف هستند و لزوماً معنای عددی یا ترتیبی ندارند. برای مثال، اگر ویژگی‌ای سه مقدار کدگذاری‌شده داشته باشد، نباید فرض کنیم مقدار ۲ از مقدار ۱ بزرگ‌تر یا مهم‌تر است؛ این اعداد صرفاً شناسهٔ دسته‌ها هستند.

فایل‌های زیر در نوت‌بوک مربوط به این بخش هستند که در قسمت اول به dataframe تبدیل کردید :

- soybean_train.csv
- soybean_test.csv

مدل Naive Bayes را روی داده‌های آموزشی آموزش دهید.(به صورت معمولی - بدون لگاریتم) سپس دقت آن را روی داده‌های آزمون محاسبه کنید.

برای هر نمونهٔ آزمون، امتیاز تمام کلاس‌ها را قبل از انتخاب کلاس ذخیره کنید. تعداد نمونه‌هایی را محاسبه کنید که امتیاز تمام کلاس ها برابر صفر است .

برای حداقل ۳ نمونه ای که امتیاز تمام کلاس‌ها صفر است، بررسی کنید که کدام ویژگی یا ویژگی‌ها باعث صفرشدن حاصل‌ضرب احتمال‌ها شده‌اند.

۱. چرا ممکن است امتیاز تمام کلاس‌ها برای یک نمونه صفر شود؟

۲. تفاوت این مشکل با Underflow چیست؟

۳. وقتی تمام امتیازها صفر هستند، مدل چگونه می‌تواند کلاس را انتخاب کند؟

۶. هموارسازی لاپلاس و لیدستون (هموارسازی جمعی)

در سوال قبل دیدیم که اگر یک مقدار ویژگی در یک کلاس از داده‌های آموزشی مشاهده نشده باشد، احتمال شرطی آن صفر می‌شود. این موضوع ممکن است باعث شود امتیاز یک کلاس یا حتی تمام کلاس‌ها برای یک نمونهٔ آزمون صفر شود.

برای کاهش این مشکل، در حالت کلی از **هموارسازی جمعی** (Additive Smoothing) یا **هموارسازی لیدستون** (Lidstone Smoothing) استفاده می‌کنیم که حالت خاص و معروف آن به ازای $\alpha = ۱$ با نام **هموارسازی لاپلاس** (Laplace Smoothing) شناخته می‌شود.

ایدهٔ اصلی ساده است: به شمارش هر مقدار ویژگی، یک مقدار کوچک α (که در هموارسازی لیدستون می‌تواند کمتر از ۱ باشد) اضافه می‌کنیم تا احتمال‌های شرطی صفر نشوند. برای یک ویژگی دسته‌ای، فرمول به شکل زیر است:

$$P(X_i = v \mid C) = \frac{N(X_i = v, C) + \alpha}{N(C) + \alpha K_i}$$

که در آن:

- $N(X_i = v, C)$ تعداد نمونه‌های کلاس C است که ویژگی X_i در آن‌ها مقدار v دارد.
- $N(C)$ تعداد نمونه‌های آموزشی متعلق به کلاس C است.
- K_i تعداد مقدارهای ممکن ویژگی X_i در مقدار های آن ویژگی است.
- α پارامتر هموارسازی است.

در این تمرین، برای هر ویژگی یک مجموعهٔ ثابت از مقدارهای ممکن تعریف کنید. اگر مقدار جدیدی در آزمون ظاهر شود که در داده‌های آموزشی دیده نشده است، آن را در یک دستهٔ ویژهٔ «ناشناخته» قرار دهید. در صورت استفاده از این قرارداد، آن دسته نیز باید در K_i لحاظ شود.

وقتی $\alpha = ۰$ باشد، فرمول به تخمین بدون هموارسازی برمی‌گردد. برای $\alpha > ۰$، احتمال‌های شرطی از صفرشدن ناشی از شمارش صفر جلوگیری می‌کنند.

مدل خود را طوری تغییر دهید که مقدار α ورودی تابع آموزش باشد. مدل باید هم حالت بدون هموارسازی و هم حالت هموارسازی را پشتیبانی کند.

با استفاده از فایل‌های soybean_train.csv و soybean_test.csv، مدل را با مقدارهای زیر آموزش دهید و ارزیابی کنید:

$$\alpha \in \{۰/۰,\ ۰/۰۱,\ ۰/۰۵,\ ۰/۱۰\}$$

دقت آزمون و تعداد نمونه‌هایی را که امتیاز تمام کلاس‌هایشان صفر است را ثبت کنید.

۱. کدام مقدار α بهترین دقت را در آزمایش شما ایجاد کرده است؟

۲. با افزایش α، تعداد نمونه‌هایی که تمام امتیازهایشان صفر است چه تغییری می‌کند؟

۳. آیا بیشترین مقدار α الزاماً بهترین دقت را ایجاد می‌کند؟ توضیح دهید.

۴. چرا بهتر است مقدار α را به‌عنوان پارامتر قابل تنظیم مدل پیاده‌سازی کنیم؟

۷. آیا هموارسازی همیشه دقت را افزایش می‌دهد؟

در سوال‌های قبل، هموارسازی لاپلاس را روی مجموعهٔ Soybean بررسی کردیم. در این سوال، همان روش را روی مجموعهٔ کامل Mushroom آزمایش می‌کنیم.

مدل Naive Bayes را با تمام ویژگی‌های مجموعهٔ mushroom_full_train.csv آموزش دهید و آن را روی mushroom_full_test.csv ارزیابی کنید.

چهار حالت زیر را مقایسه کنید:

۱. احتمال‌های معمولی ، بدون هموارسازی

۲. احتمال‌های لگاریتمی، بدون هموارسازی

۳. احتمال‌های معمولی، با هموارسازی

۴. احتمال‌های لگاریتمی، با هموارسازی

برای حالت‌های هموارشده، از یک مقدار مثبت α استفاده کنید و مقدار آن را در گزارش خود مشخص کنید.

پیکربندی مدل	دقت آزمون
مستقیم، بدون هموارسازی	
لگاریتمی، بدون هموارسازی	
مستقیم، با هموارسازی	
لگاریتمی، با هموارسازی	

۱. آیا دقت مدل با اضافه‌کردن هموارسازی تغییر کرده است؟

۲. آیا هموارسازی باعث افزایش دقت شده یا آن را کاهش داده است؟

۳. با مقایسهٔ نتایج Mushroom و ،Soybean توضیح دهید چرا نمی‌توان گفت هموارسازی در تمام مجموعه‌های داده دقت را افزایش می‌دهد.

۴. تفاوت نقش لگاریتم و هموارسازی را در یک یا دو جمله بیان کنید.